

Statistical Learning HW 7

丁博 18307110088

(1) 解: 引入拉格朗日乘子 α 和 μ , 则原问题的拉格朗日函数为:

$$L(w, b, \beta; \alpha, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \beta_i - \sum_{i=1}^N \alpha_i \{y_i(w \cdot x_i + b) - 1 + \beta_i\} - \sum_{i=1}^N \mu_i \beta_i$$

其中 $\alpha_i, \mu_i \geq 0$

则: dual function: $\theta(\alpha, \mu) = \inf_{w, b, \beta} L(w, b, \beta; \alpha, \mu)$

$$\Rightarrow \text{求解极小问题: } \begin{cases} \frac{\partial L}{\partial w} = w - \sum_{i=1}^N \alpha_i y_i x_i = 0 \\ \frac{\partial L}{\partial b} = -\sum_{i=1}^N \alpha_i y_i = 0 \\ \frac{\partial L}{\partial \beta_i} = 2C\beta_i - \alpha_i - \mu_i = 0, \text{ for } i=1, 2, \dots, N \end{cases}$$

$$\therefore \text{代入有: } \theta(\alpha, \mu) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j x_i \cdot x_j + \sum_{i=1}^N \alpha_i - \frac{1}{4C} \sum_{i=1}^N (\alpha_i + \mu_i)^2$$

[$x_i \cdot x_j$ 即 $(x_i \cdot x_j)$, 内积]

\therefore dual problem 为:

$$(D) \quad \begin{aligned} \max_{\alpha, \mu} \quad & -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i - \frac{1}{4C} \sum_{i=1}^N (\alpha_i + \mu_i)^2 \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & \alpha_i \geq 0, \mu_i \geq 0 \text{ for } i=1, 2, \dots, N \end{aligned}$$

(2) 证明: 由正定核函数的充要条件, 亟即证 $K = [k(x_i, x_j)]_{m \times m}$ (即 kernel function $k(x, z) = (x \cdot z)^p$ 对应的 Gram 矩阵) 半正定:

任意取一个 m 维向量 $C = (C_1, C_2, \dots, C_m)^T \in \mathbb{R}^m$, 则有:

$$C^T K C = \sum_{i=1}^m \sum_{j=1}^m C_i C_j k_{ij} = \sum_{i=1}^m \sum_{j=1}^m C_i C_j (x_i \cdot x_j)^p \quad (\#)$$

下面证明: 对任意整正数 p , 均存在一个映射 (记为 φ), 使得 $(x_i \cdot x_j)^p = \varphi(x_i) \cdot \varphi(x_j)$

“ \cdot ” 为内积

\Rightarrow 用数学归纳法, 假设 x_i 与 x_j 为 n 维向量:

1) $p=1$ 时, 令 $\varphi(x) = x$ 即可, 成立 $x_i \cdot x_j = \varphi(x_i) \cdot \varphi(x_j)$

2) 假设 $p \neq 1$ 时 $p=n-1$ 时命题成立, 即 \exists 映射 φ , s.t. $(x_i \cdot x_j)^{n-1} = \varphi(x_i) \cdot \varphi(x_j)$

则 $p=n$ 时: $(x_i \cdot x_j)^n = (x_i \cdot x_j)(x_i \cdot x_j)^{n-1} = (x_i \cdot x_j)[\varphi(x_i) \cdot \varphi(x_j)]$

$$\text{可令 } G(x) = \begin{bmatrix} \varphi^T(x) \\ x_1 \varphi(x) \\ x_2 \varphi(x) \\ \vdots \\ x_n \varphi(x) \end{bmatrix} \quad \text{若 } \varphi(x) \in \mathbb{R}^m \text{ 则 } G(x) \in \mathbb{R}^{m(n+1)}$$

∴ 由内积定义, $G(x) \cdot G(y) = (x_1 y_1) [\varphi(x_1) \cdot \varphi(y_1)] + (x_2 y_2) [\varphi(x_2) \cdot \varphi(y_2)] + \dots$
 $= (x \cdot y) [\varphi(x) \cdot \varphi(y)]$

∴ 有 $(x_i \cdot x_j)^p = (x_i \cdot x_j) [\varphi(x_i) \cdot \varphi(x_j)] = G(x_i) \cdot G(x_j)$

即 $p=n$ 时命题成立

线上, 得对 $\forall p \in \mathbb{N}^+$, \exists 一个映射 (记为 φ), s.t. $(x_i \cdot x_j)^p = \varphi(x_i) \cdot \varphi(x_j)$

→ 该映射对不同的 p 不同

代入上面结果于 (#) 式, 即有: $\exists \varphi$, s.t.

$$\begin{aligned} C^T K C &= \sum_{i=1}^N \sum_{j=1}^N C_i C_j (x_i \cdot x_j)^p = \sum_{i=1}^N \sum_{j=1}^N [\varphi(x_i) \cdot \varphi(x_j)] C_i C_j \\ &= \left(\sum_{i=1}^N C_i \varphi(x_i) \right) \left(\sum_{j=1}^N C_j \varphi(x_j) \right) = \left\| \sum_{i=1}^N C_i \varphi(x_i) \right\|_2^2 \geq 0 \\ \therefore K \text{ 半正定} &\Leftrightarrow K(x, z) = (x \cdot z)^p \text{ 为正定核} \quad \text{证毕} \quad \# \end{aligned}$$

(2) 解: 支持向量为: ②

支持向量是定义为在超平面 $w^T x + b = 1$ 或 -1 上的点, 图中只有 ② 满足该定义 (且 ④ 并不是错分类的点)

(3) 解: 支持向量为: ② ③ ④ ⑥

原因: 在软间隔最大化求解中, 根据 KKT 条件要求, 若对偶变量 $\alpha_i > 0$, ^{参照} (讲义中的表示)

则有 $y_i(w^T x_i + b) = 1 - \xi_i$ 即该样本为支持向量

具体而言, 分为以下几种:

1> ~~0 < \alpha_i < C~~ $0 < \alpha_i < C$ 则 $\xi_i = 0$ ($\mu_i > 0$) \Rightarrow 恰在间隔边界, 对应图中 ⑥

2> $\alpha_i = C$ 则 $\mu_i = 0 \Rightarrow \begin{cases} 0 < \xi_i < 1, \text{ 正负分类但在间隔平面与分离平面间, 对应图中 ②} \\ \xi_i = 1, \text{ 落在分离平面上, 图中无此点} \\ \xi_i > 1, \text{ 错分类, 对应图中 ③ 和 ④} \end{cases}$

∴ 支持向量为 ② ③ ④ ⑥